E1 DOCUMENTAÇÃO DO SCRIPT · MULTI-STEP

Experimento E1: o LLM raciocina em etapas e responde em JSON

Como o script funciona, quais prompts usa, como mede o resultado e por que errou 45 das 100 perguntas

Notebook E1_MultiStep_LLM_METRICAS_Amostra_v2 · ConvFinQA (100 perguntas) · llama3:8b via Ollama + AutoGen

E1

OBJETIVO

Decompor o problema melhora a resposta direta?

O E1 muda uma única coisa em relação ao E0: em vez de "Return only the final answer", o modelo é instruído a resolver a pergunta em cinco etapas e a devolver um JSON estruturado. Continua sendo uma só chamada, sem programa, sem calculadora e sem críticos.

Igual ao E0

Modelo llama3:8b, temperatura 0,2, persona do system prompt, montagem da entrada, as mesmas 100 perguntas e o mesmo critério de acerto.

55%

EM com escala percentual (E0: 46%)

49%

EM estrito (E0: 38%)

87%

respostas com JSON válido

1

chamada ao LLM por pergunta

7,7 s

latência média (E0: 3,8 s)

1.436

tokens médios por pergunta

E1

ESTRUTURA DO SCRIPT

Um notebook, três células, nove blocos de código

1 **Célula 1**
Imprime data e hora de início

2 **Célula 2**
Todo o experimento (detalhado ao lado)

3 **Célula 3**
Imprime data e hora de término

A estrutura é a mesma do E0. Os blocos em destaque são os que mudaram.

Configuração CSV, modelo, Ollama, MAX_ITEMS, temperatura, preços

Prompts SYSTEM_PERSONA e E1_PROMPT_TEMPLATE (etapas + JSON)

Estrutura de dados MultiStepResult: + evidence, operation, reasoning_summary, unit

Utilitários leitura de JSON, _to_float, _answers_match

Métricas as do E0 + conformidade do formato JSON

AutoGen _base_llm_config, build_agents ("MultiStep_LLM"), _usage_totals

Montagem da entrada split_dialogue, build_fields, build_e1_prompt

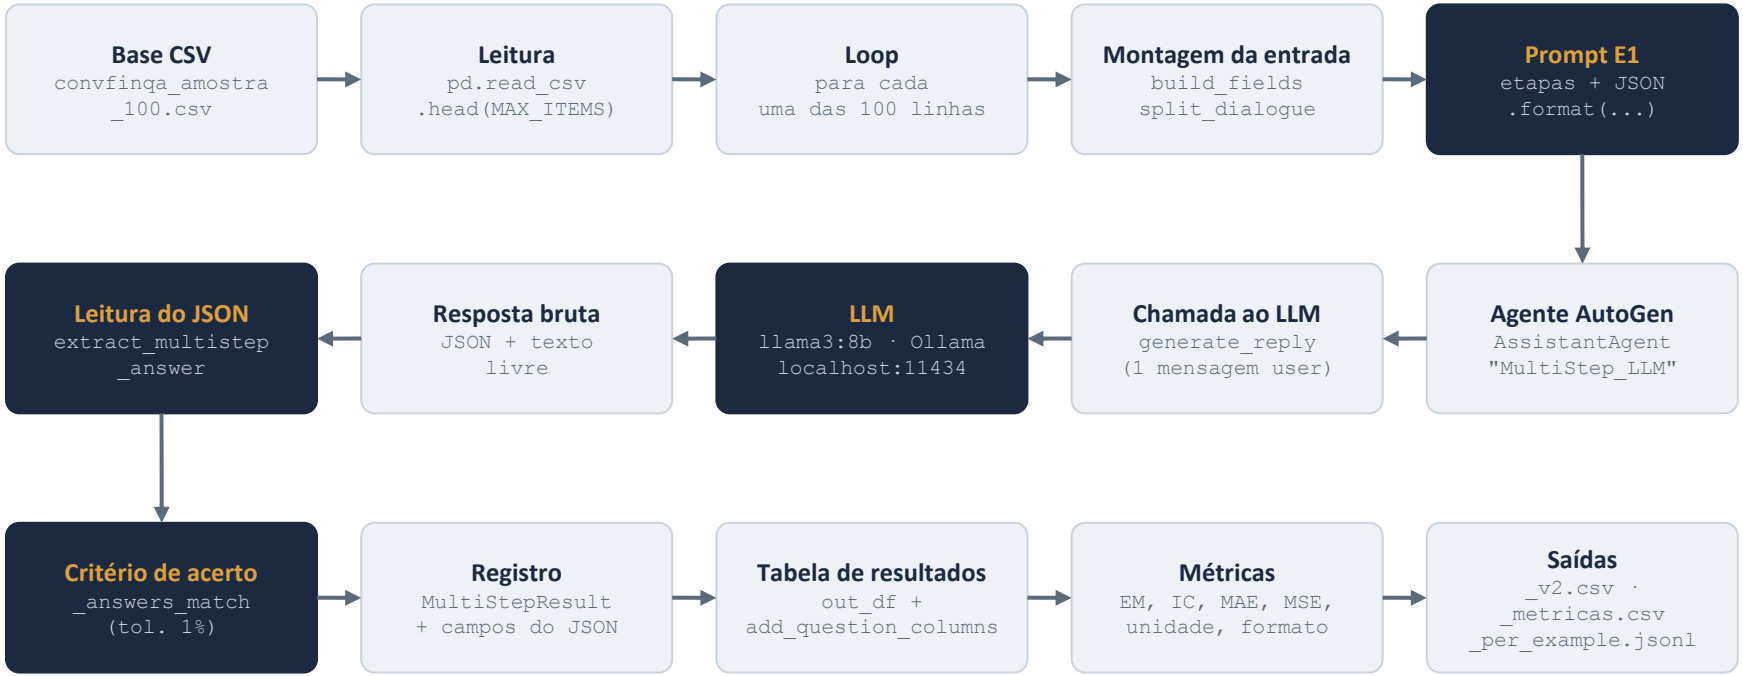
Fluxo E1 extract_multistep_answer e run_multistep

main() loop, CSVs de saída, resumo; avaliador reasoning-level opcional

E1

DIAGRAMA DO FLUXO

Da base de dados à resposta avaliada



Mesmo fluxo do E0. Mudam o prompt, o nome do agente e a leitura da resposta, que agora procura o JSON antes de recorrer ao texto livre.

E1

COMO A BASE É RECEBIDA

A mesma entrada do E0, dividida em quatro blocos

O CSV (100 linhas)

text: relatório financeiro (texto + tabela HTML) seguido do diálogo "Question: … Answer: … Question: …".
output: gabarito numérico.
Média de 4.423 caracteres por linha.

Como o texto é dividido

split_dialogue procura o primeiro "Question:" da linha.
Antes dele: TEXT (relatório).
Pares Question/Answer: HISTORY.
Última pergunta, sem resposta: QUESTION.
64 das 100 linhas têm histórico.

EXEMPLO REAL · LINHA 9 DO CSV, JÁ DIVIDIDA

```
QUESTION:
what percentage change does this represent?

TEXT:
corporate/other includes global staff
functions ( includes finance , risk , ...
[3.198 caracteres de relatório e tabela]

TABLE:
(not provided separately -- any table is
included in the TEXT block)

HISTORY:
Question: what are the total operating
  expenses in 2009?     Answer: 1420.0
Question: what about in 2008?  Answer: 510.0
Question: what is the net change? Answer: 910.0
```

E1

PROMPTS UTILIZADOS

Persona fixa e o prompt E1 do documento

SYSTEM PROMPT · SYSTEM_PERSONA (ÍNTEGRA)

```
You are a financial analysis agent
specializing in interpreting earnings
reports and financial statements. Your
task is to answer specific financial
questions based on the given context
from financial reports.
```

O que muda em relação ao E0

As duas primeiras frases e os blocos de entrada são idênticos. A linha "Return only the final answer." foi trocada pelas cinco etapas e pelo formato JSON do documento de ablação.

PROMPT DO USUÁRIO · JSON E BLOCOS COMPACTADOS

```
You are a financial question answering
assistant.

Use the provided financial context to
answer the question.

Analyze the financial question in stages:
1. Identify the relevant values.
2. Identify what the question is asking.
3. Determine the required calculation.
4. Compute the result.
5. Return the final answer.

Return JSON:
{ "evidence": [], "operation": "",
  "reasoning_summary": "",
  "answer": null, "unit": "" }

QUESTION: {question}   TEXT: {text}
TABLE: {table}   HISTORY: {history}
```

E1

A CHAMADA AO LLM

Um agente AutoGen novo para cada pergunta

BUILD_AGENTS E RUN_MULTISTEP (SIMPLIFICADO)

```
agent = AssistantAgent(
    name="MultiStep_LLM",
    system_message=SYSTEM_PERSONA,
    llm_config={
        "config_list": [{
            "model": "llama3:8b",
            "base_url": "http://localhost:11434/v1",
            "api_key": "ollama"}],
        "temperature": 0.2,
        "timeout": 600,
        "cache_seed": None},
    human_input_mode="NEVER",
    max_consecutive_auto_reply=1,
    code_execution_config=False)

reply = agent.generate_reply(
    messages=[{"role": "user",
               "content": prompt}])
```

- **Mesma configuração do E0;** muda só o nome do agente e o prompt.
- **Um agente por pergunta:** o histórico chega apenas pelo bloco HISTORY.
- **Respostas bem mais longas:** 193 tokens de saída em média (E0: 29), com picos de 1.098.
- **Latência:** 7,7 s por pergunta em média (E0: 3,8 s), entre 4,6 s e 29,3 s.
- **cache_seed = None:** tokens e latência refletem chamadas reais.

E1

DA RESPOSTA AO NÚMERO

Primeiro o JSON; se falhar, o texto livre

1 **`json`**
"answer" do JSON já é um número

2 **`json_texto_limpo`**
"answer" veio como texto ("25%") e foi limpo

3 **`json_sem_answer`**
JSON válido, mas "answer" vazio ou nulo: erro

4 **`fallback_…`**
JSON inválido: aplica a extração de texto livre do E0

`_parse_json_response` pega o último bloco JSON completo da resposta, ignorando chaves dentro de textos.

Modo de leitura	Respostas	Acertos
json	76	40 (53%)
json_texto_limpo	8	6 (75%)
fallback (texto livre)	13	9 (69%)
json_sem_answer	3	0 (0%)

Ponto fraco

O modelo costuma escrever o JSON primeiro, com uma resposta "chutada", e só depois raciocinar em texto. O script lê o JSON; quando o raciocínio que vem depois chega a outro número, esse número é ignorado. Isso causou 5 erros.

E1

CRITÉRIO DE ACERTO

Dois critérios: estrito e com escala percentual

EM estrito · _answers_match

Certo se |resposta − gabarito| ≤ 1% × max(1, |gabarito|). Ou seja: erro de até 1% do gabarito, ou até 0,01 quando o gabarito é menor que 1.

EM com escala percentual

Mesma regra; nas perguntas de percentual aceita também gabarito × 100 ou ÷ 100. O ConvFinQA guarda 36,93% como 0,3693.

Pergunta (linha 16)	Gabarito	Resposta do E1	Estrito	Escala %
what percentage, then, of the liquidity did that amount represent?	0,36931	36,93	errado	certo

- **Perguntas de percentual** são identificadas por palavras-chave (percent, %, portion, ratio, represent…): 24 das 100.
- **Critério principal da ablação:** o EM com escala percentual. O estrito é a verificação de robustez.
- **Diferença no E1:** 6 perguntas só estão certas no critério com escala (linhas 3, 12, 16, 20, 31 e 62): 55% contra 49%.

E1

MÉTRICAS UTILIZADAS

As do E0 e a conformidade com o formato

EM (Exact Match)

% de perguntas certas. Estrito e com escala percentual.

IC de Wilson (95%)

Faixa provável do EM verdadeiro. Confiável com n = 100.

MAE e erro relativo

Média de |resposta − gabarito|, absoluta e relativa, só em pares numéricos.

MSE e RMSE

Média dos erros ao quadrado e sua raiz. Penalizam muito os erros grandes.

Unit accuracy heurística

Em perguntas com unidade no texto, resposta a menos de 50% do gabarito.

Conformidade de formato

NOVA: % de JSON válido e % de cada campo preenchido.

Tokens e latência

Entrada e saída por pergunta e tempo de resposta.

Custo hipotético

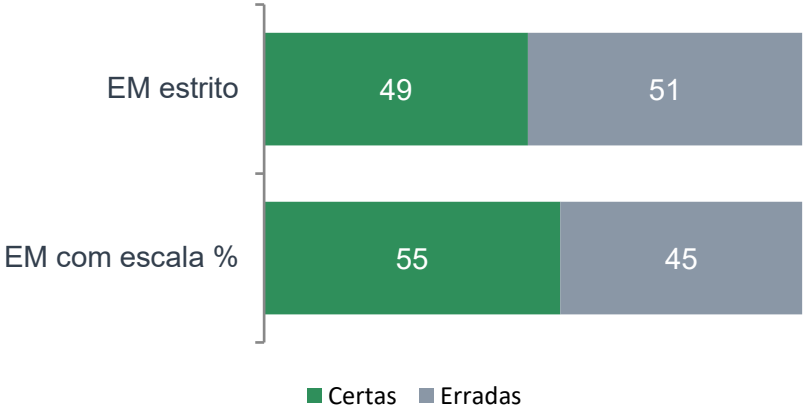
O mesmo volume de tokens precificado em APIs pagas.

Opcional e não executado: avaliação reasoning-level por LLM. Kappa e Qui-Quadrado ficam no notebook de comparação E0–E7.

E1

RESULTADOS DO E1

55 acertos em 100 perguntas



Métrica	Valor [IC 95%]
EM com escala percentual	55% [45,2% – 64,4%]
EM estrito	49% [39,4% – 58,7%]
Perguntas de percentual certas	10 de 24
Demais perguntas certas	45 de 76
Unit accuracy heurística	60,0% (n = 90)
MAE (n = 97)	121.944,8
RMSE	1.074.644,1
Erro relativo médio	1.164.536%

100
chamadas ao LLM

765,8 s
latência total (7,7 s por pergunta)

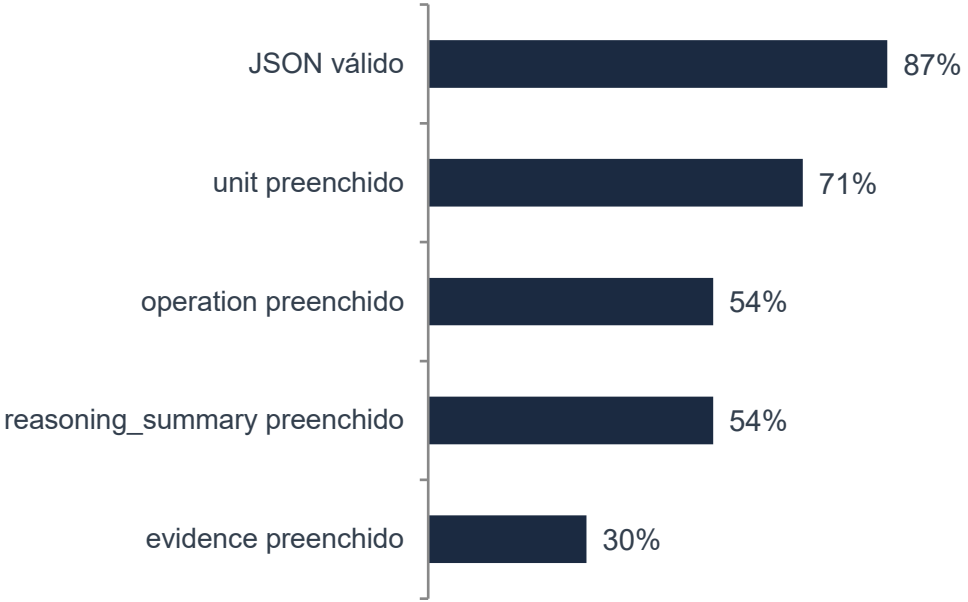
143,6 mil
tokens (87% de entrada)

Custo hipotético em API paga: US$ 0,008 (Llama 3.1 8B na Groq) ou US$ 0,030 (GPT-4o mini). Execução real: local, sem custo de API.

E1

CONFORMIDADE COM O FORMATO

O JSON é válido, mas muitas vezes incompleto



- **Em 33 respostas** o JSON era válido, mas só com o campo answer: evidence, operation e reasoning_summary vieram vazios.
- **O raciocínio foi para fora do JSON:** 93 das 100 respostas têm texto depois do JSON (em média 400 caracteres), onde o modelo percorre as cinco etapas.
- **Consequência:** a decomposição acontece, mas no texto livre, e o script só lê o JSON.

E1

COMPARAÇÃO COM O E0

O que mudou pergunta a pergunta

	E1 acertou	E1 errou
E0 acertou	37	**9**
E0 errou	**18**	36

No McNemar da comparação E0–E7, 18 × 9 dá p (Holm) = 0,74: a melhora não é estatisticamente significativa.

+9

perguntas no saldo (18 ganhas, 9 perdidas)

18 que o E1 ganhou

9 eram erros de extração do E0: com o JSON, o número certo passou a ser lido (22, 29, 44, 51, 66, 75, 83, 85, 87). Outras 6 eram perguntas de continuação e 3, contas que o E0 errava.

9 que o E1 perdeu

Percentuais calculados com outra fórmula (9, 57, 67, 98), resposta do JSON diferente do raciocínio (21, 63), JSON vazio (45), variação no lugar do valor (77) e opções sem multiplicar pelo preço (40).

E1

POR QUE MAE E MSE SÃO TÃO ALTOS

Poucos erros gigantes dominam a média

Linha	Pergunta	Gabarito	Resposta
40	proceeds from employee options, fev/2004	11.556.103	**1.032.717**
47	what is that value less 1?	0,044	**1.127.587**
52	total including 2007	102.964	**26.996**

- **Só a linha 40** erra por 10,5 milhões e responde por cerca de 108 mil dos 122 mil do MAE.
- **O MAE do E1 é maior que o do E0** (122 mil contra 40 mil) apesar de o E1 acertar mais: a métrica reflete poucos casos extremos, não a qualidade geral.
- **Por isso** o EM e o IC são as métricas que servem para comparar os experimentos.

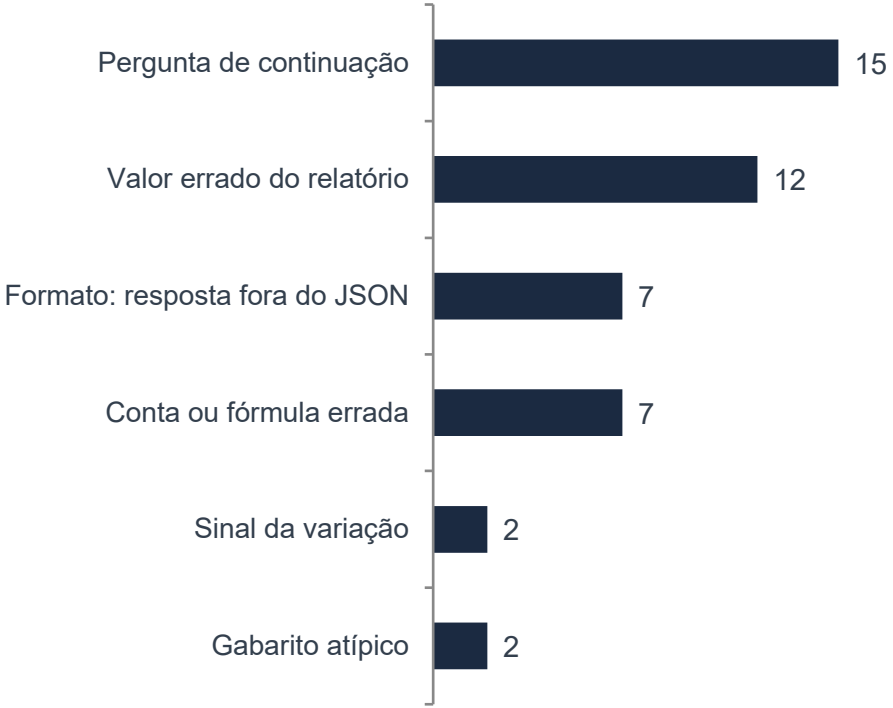
Alternativas mais robustas

Mediana do erro absoluto, ou erro relativo limitado a 100%. Assim um único erro de escala não domina o resultado.

E1

ANÁLISE DOS ERROS

As 45 perguntas erradas, por motivo provável



Pergunta de continuação · 15

Dependem do histórico ("this", "that"): o modelo resolve outra coisa ou usa outra base.

Valor errado do relatório · 12

Linha, coluna, ano ou item errado da tabela.

Formato · 7

A resposta do JSON diverge do raciocínio escrito depois, ou o JSON veio vazio ou inválido.

Conta ou fórmula errada · 7

Fórmula diferente da pedida, conta incompleta ou com valores errados.

Mais: sinal da variação (2) e gabarito atípico (2). Classificação feita a partir da resposta bruta (raw_response) de cada pergunta.

E1

ERROS DE FORMATO · 7 PERGUNTAS

A resposta certa ficou fora do JSON

Linha	O que o modelo escreveu (trecho)	Gabarito	Lido
21	JSON: "answer": 24.0 … depois: "The average tax benefit is: 78.0 / 3 = 26.0 million … the answer is 26.0."	26	24
23	JSON: "answer": 20.3 … depois: "$978.4 - $998.7 = -$20.3 million … a decrease of $20.3 million."	-20,3	20,3
63	JSON: "answer": 241.0 … depois: "The value of Apple Inc. in 2006 is $100"	100	241
64	JSON: "answer": null … depois: "(3219192 / 11900000) * 100 = 27.0%"	0,27052	vazio
32	JSON: "answer": 101.0 … depois: "101 mmboe out of a total of 728 mmboe, or approximately 14% of the total."	0,13874	101
45	JSON vazio ("answer": null) seguido de uma cópia do próprio prompt: "QUESTION: what is the percent of shares…"	0,15116	vazio

O modelo preenche o JSON antes de raciocinar e depois resolve a pergunta no texto. Nas linhas 21, 23, 32, 63 e 64 o raciocínio posterior chegou à resposta certa: com elas, o E1 iria de 55% para até 60%.

E1

PERGUNTAS DE CONTINUAÇÃO · 15 PERGUNTAS

Continua sendo o maior grupo de erros

Linha	Pergunta	O que era pedido	Gabarito	Resposta
9	what percentage change does this represent?	910 ÷ 510 (net change ÷ 2008)	1,78431	78,43
47	what is that value less 1?	1,044 − 1 (razão do turno anterior)	0,044	1127587
14	what is the difference between 100% and that increase?	100% − 0,23	99,77	0,23
52	what about the total including 2007?	75.968 + valor de 2007	102964	26996
48	and what was that for the decrease in interest rates?	efeito da queda de juros (82,5)	82,5	-91,3
77	what was the value of outstanding commercial papers in 2007?	o valor de 2007, não a variação	2,36	0,23

As cinco etapas não resolveram o problema principal do E0: quando a resposta depende dos números dos turnos anteriores, o modelo ainda responde outra pergunta, repete um valor do histórico ou usa uma base diferente para o percentual.

E1

DEMAIS CATEGORIAS · 23 PERGUNTAS

Leitura do relatório, contas, sinais e casos atípicos

D

Valor errado do relatório · 12

Pega outra linha, coluna ou item. Ex.: linha 58, usou o caixa total (121.251 − 81.570) em vez do das subsidiárias no exterior. Linha 8: o saldo de 1º de janeiro de 2010 em vez do total.

E

Conta ou fórmula errada · 7

Linha 39: somou as variações anuais (87,3) em vez de 157,38 − 100. Linha 57: ganho ÷ inicial (85,81%) em vez de valor ÷ inicial (185,81%). Linha 40: deu o nº de opções sem multiplicar pelo preço.

B

Sinal da variação · 2

Magnitude certa, sinal diferente do gabarito (linhas 36 e 79). O ConvFinQA representa quedas como número negativo.

F

Gabarito atípico · 2

Linhas 4 e 5: gabaritos que não batem com o texto (o relatório diz 2,2 anos; o gabarito, 2,1). Os mesmos casos apareceram no E0.

E1

APÊNDICE 1/5 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
21	and what is, in millions, the average tax benefit between those three years?	26	24	**Formato: resposta fora do JSON**	JSON com 24; o raciocínio escrito depois do JSON chega a 26 (correto)
23	what was the net change in revenues from 2003 to 2004?	-20,3	20,3	**Formato: resposta fora do JSON**	JSON com 20,3; a conta depois do JSON dá −20,3 (correto)
32	and how much does that change represent in relation to this total?	0,13874	101	**Formato: resposta fora do JSON**	JSON com 101; o texto depois do JSON diz "aprox. 14%" (correto)
45	what is the percent of shares not related to post-merger services?	0,15116	vazio	**Formato: resposta fora do JSON**	JSON vazio; o modelo repetiu o prompt em vez de responder
63	what was the 2006 value?	100	241	**Formato: resposta fora do JSON**	JSON com 241; o texto depois do JSON diz $100 (correto)
64	and how much was the total number of customers as a percentage of this total amount?	0,27052	vazio	**Formato: resposta fora do JSON**	JSON com answer null; o texto depois calcula 27,0% (correto)
72	what was, then, the change over the year?	-1,9	7,4	**Formato: resposta fora do JSON**	JSON inválido ("1.9 million ($9.3 – $7.4)"); a leitura pegou 7,4 e o sinal também diverge
36	in that same period, what was the change in the total of current liabilities?	-42,8	117	**Sinal da variação**	JSON com 117; o texto calcula 42,8 como aumento, e o gabarito é −42,8
79	what is the net change in operating leases from 2019 to 2020?	-190	190	**Sinal da variação**	Magnitude certa (190), sem o sinal negativo do gabarito

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
9	what percentage change does this represent?	1,78431	78,43	**Pergunta de continuação**	Pedia 910 ÷ 510 (histórico); calculou (910 − 510) ÷ 510 = 78,43%
10	and what was that percentage representation in the previous year, in 2011?	0,52288	40	**Pergunta de continuação**	Pedia o percentual de 2011 do turno anterior; usou outros valores (40%)
11	what is the value of the investment in 2014?	144	215	**Pergunta de continuação**	O histórico falava do S&P 500; pegou a linha da empresa (215)
14	what is the difference between 100% and that increase?	99,77	0,23	**Pergunta de continuação**	Pedia 100% − 0,23; devolveu 0,23 (e o texto diz 77%)
24	and the percentage change of this value?	0,97734	-34,5	**Pergunta de continuação**	Pedia a variação percentual; devolveu uma diferença absoluta (−34,5)
46	so what was the percentage change during this time?	1,78431	90,1	**Pergunta de continuação**	Pedia 910 ÷ 510 (histórico); calculou outra variação (90,1)
47	what is that value less 1?	0,044	1127587	**Pergunta de continuação**	Pedia 1,044 − 1 do turno anterior; respondeu 1.127.587
48	and what was that for the decrease in interest rates?	82,5	-91,3	**Pergunta de continuação**	Pedia o efeito da queda de juros; repetiu o do aumento (−91,3)
52	what about the total including 2007?	102964	26996	**Pergunta de continuação**	Pedia 75.968 + valor de 2007; devolveu só o de 2007

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
61	and what is this representation as a portion of the 2009 total?	0,97656	1,5625	**Pergunta de continuação**	Pedia 1,5625 ÷ 1,6; repetiu a razão 1,5625
65	so what was the percentage change during this time?	0,21795	8	**Pergunta de continuação**	Pedia a variação percentual da taxa do histórico; usou outra receita (8%)
67	so what was the percentage change during this time?	0,28148	22,2	**Pergunta de continuação**	Variação percentual da pergunta anterior calculada com outra base (22,2%)
77	what was the value of outstanding commercial papers in 2007?	2,36	0,23	**Pergunta de continuação**	Pedia o valor de 2007; calculou a variação 2007–2008 (0,23)
80	and what is the percentage this change represents of those losses in 2005?	0,70705	133,9	**Pergunta de continuação**	Pedia 71,2 ÷ perdas de 2005; devolveu 133,9
98	what is the percent change?	-0,17266	13,4	**Pergunta de continuação**	Pedia a variação do saldo do histórico; calculou outra (13,4%)
6	what is the value of operating leases over the total minimum payments?	0,68368	0,0995	**Valor errado do relatório**	Dividiu valores errados da tabela (0,0995 em vez de 0,68)
8	what was the balance of total pci consumer loans in 2010?	19097	25544	**Valor errado do relatório**	Pegou o saldo de 1º de janeiro de 2010 (25.544)
19	and what was the total of benefits obligations in 2018, also in millions?	31	25	**Valor errado do relatório**	Leu 25 na tabela de obrigações; gabarito 31

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
38	what is the sum of cash provided by operating activities and used by investing activities in…	1184	1378	**Valor errado do relatório**	Somou linhas erradas da demonstração de caixa (1378)
58	and only from 2011 to 2012, what was the change in the company 2019s cash, cash equivalents …	28,3	39581	**Valor errado do relatório**	Usou o caixa total, não o das subsidiárias no exterior
59	how many shares were repurchased during 2017?	3,4	1,8	**Valor errado do relatório**	Informou 1,8 mi de ações; gabarito 3,4 mi
74	what was the value of the dow jones u.s. technology supersector index in 2011?	100	130	**Valor errado do relatório**	Pegou 130 em vez do valor-base 100 do índice em 2011
84	what was the balance of unpaid losses in the beginning of 2008?	7603	37,2	**Valor errado do relatório**	Pegou $37,2 bi (outro item) em vez de 7.603
88	what is the net change in the total consolidated revenues from 2011 to 2012?	182	169,6	**Valor errado do relatório**	Usou outra linha da tabela (2246,4 − 2076,8)
91	what was the total amount of resale agreements in 2008, in millions?	20800	200,265	**Valor errado do relatório**	Pegou a linha da tabela e ainda mudou a escala (200,265)
92	and what was it in 2016?	26,4	42	**Valor errado do relatório**	Pegou o saldo do empréstimo (42,0) em vez da despesa de juros
96	what was the change in value of cds that were excluded between 2013 and 2014?	4,37	11,26	**Valor errado do relatório**	Usou itens diferentes da tabela de depósitos (11,26)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
26	and what was the change in value of that stock considering the original amount invested in i…	227,11	vazio	**Conta ou fórmula errada**	Não informou o número; tratou como variação % em vez de 327,11 − 100
39	what was the variation in the value of the fidelity national information services inc . from…	57,38	87,3	**Conta ou fórmula errada**	Somou as variações anuais (87,3) em vez de 157,38 − 100
40	what is the total value of proceeds from the issuance of employee options during february 2004?	11556103,23	1032717	**Conta ou fórmula errada**	Deu o nº de opções, sem multiplicar pelo preço de exercício
55	what is the average balance for these years?	8,5	7	**Conta ou fórmula errada**	Média calculada com valores errados (JSON 7; texto 6160,5)
57	what return rate does this represent?	1,8581	85,81	**Conta ou fórmula errada**	Calculou ganho ÷ inicial (85,81%) em vez de valor ÷ inicial (185,81%)
69	in the year of 2018, what was the total net cash used?	2054	-2515,2	**Conta ou fórmula errada**	Subtraiu fluxos em vez de somar os caixas usados (−2515,2)
82	what was the change in net revenue between the two years?	-31,9	32,1	**Conta ou fórmula errada**	Conta com valores levemente errados (32,1) e sem sinal negativo
4	considering the amount of those 2003 earnings, what can be concluded to have been those oper…	20452,85	1,23	**Gabarito atípico**	Gabarito atípico (20452,85); modelo devolveu 1,23
5	and what is the weighted-average period over which this cost will be recognized, in years?	2,1	2,2	**Gabarito atípico**	Texto diz 2,2 anos; gabarito 2,1 (possível divergência)

CONCLUSÕES E RECOMENDAÇÕES

O E1 acerta 55%, e metade do ganho sobre o E0 vem de ler melhor a resposta

O que o E1 mostra

- 55% de acerto (IC 45–64%), +9 pontos sobre o E0, sem significância estatística.
- 9 dos 18 ganhos são perguntas que o E0 acertava no texto, mas o script lia errado.
- O modelo raciocina em etapas, mas fora do JSON.

Ajustes no script

- Pedir o JSON no fim da resposta, depois do raciocínio (5 acertos perdidos; teto de 60%).
- Tratar "decrease" como sinal negativo.
- Revisar os gabaritos das linhas 4 e 5.

Para a ablação

- Mudanças no prompt ou na leitura devem valer de E0 a E7.
- Perguntas de continuação (15) seguem como o principal erro.
- O custo dobra: 7,7 s e 1.436 tokens por pergunta.