E2

DOCUMENTAÇÃO DO SCRIPT · PoT SIMBÓLICO

Experimento E2: o LLM escreve um programa e depois o executa

Como o script funciona, quais prompts usa, como mede o resultado e por que errou 67 das 100 perguntas

Notebook E2_PoT_Symbolic_LLMExec_METRICAS_Amostra_v2 · ConvFinQA (100 perguntas) · llama3:8b via Ollama + AutoGen

E2

OBJETIVO

Uma representação formal melhora o planejamento?

O E2 deixa de pedir a resposta ao LLM. Um primeiro agente (Planner) traduz a pergunta num programa simbólico: variáveis com os valores do contexto e passos com operações permitidas. Um segundo agente (Executor) recebe só esse programa e o executa.

Igual ao E0 e ao E1

Modelo llama3:8b, temperatura 0,2, persona do system prompt, montagem da entrada, as mesmas 100 perguntas e o mesmo critério de acerto.

33%

EM com escala percentual (E1: 55%)

32%

EM estrito (E1: 49%)

39%

planos corretos (Plan Accuracy)

2

chamadas ao LLM por pergunta

20,4 s

latência média (E1: 7,7 s)

2.837

tokens médios por pergunta

E2

ESTRUTURA DO SCRIPT

Um notebook, três células, dez blocos de código

1 **Célula 1**
Imprime data e hora de início

2 **Célula 2**
Todo o experimento (detalhado ao lado)

3 **Célula 3**
Imprime data e hora de término

Os blocos em destaque são novos ou mudaram em relação ao E1.

Configuração CSV, modelo, Ollama, temperatura, INCLUDE_PLANNER_EXAMPLE

Prompts Planner (documento) + semântica + exemplos; Executor

Estrutura de dados PoTResult: plano, referência, executor, categoria

Utilitários leitura de JSON, _to_float, _answers_match

Métricas as do E0/E1 + plano (Plan Accuracy, Fidelity)

Programa simbólico normalize_plan e execute_program (referência)

AutoGen PoT_Planner e LLM_Executor, _usage_totals

Montagem da entrada split_dialogue, build_fields (igual ao E0/E1)

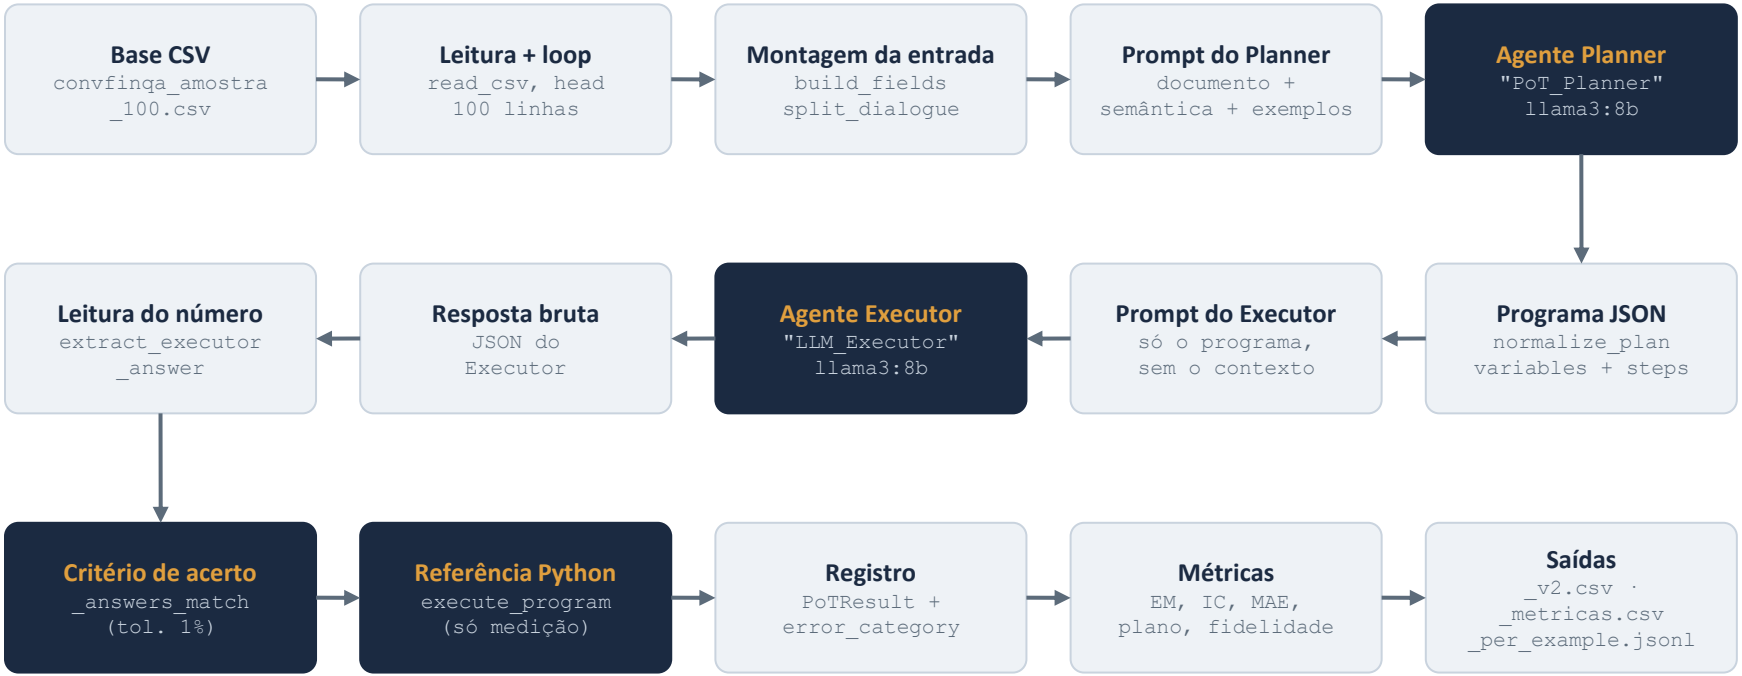
Fluxo E2 build_planner_prompt, build_executor_prompt, run_pot

main() loop, CSVs de saída, resumo com decomposição dos erros

E2

DIAGRAMA DO FLUXO

Dois agentes: um planeja, outro executa



Se o plano não vier em JSON válido, o Executor não é chamado e a pergunta conta como erro. A referência Python roda o mesmo programa só para medir o plano.

E2

COMO A BASE É RECEBIDA

A mesma entrada do E0 e do E1

O CSV (100 linhas)

text: relatório financeiro (texto + tabela HTML) seguido do diálogo "Question: … Answer: … Question: …".
output: gabarito numérico.
Média de 4.423 caracteres por linha.

Quem recebe o quê

Planner: os quatro blocos (QUESTION, TEXT, TABLE, HISTORY).
Executor: só o programa gerado pelo Planner, sem pergunta nem relatório.
64 das 100 linhas têm histórico.

EXEMPLO REAL · LINHA 9 DO CSV, JÁ DIVIDIDA

```
QUESTION:
what percentage change does this represent?

TEXT:
corporate/other includes global staff
functions ( includes finance , risk , ...
[3.198 caracteres de relatório e tabela]

TABLE:
(not provided separately -- any table is
included in the TEXT block)

HISTORY:
Question: what are the total operating
  expenses in 2009?     Answer: 1420.0
Question: what about in 2008?  Answer: 510.0
Question: what is the net change? Answer: 910.0
```

E2

PROMPT DO PLANNER

Texto do documento e a semântica das operações

DOCUMENTO DE ABLAÇÃO · OPERAÇÕES E JSON COMPACTADOS

```
You are a financial reasoning planner.

Do not calculate the final answer.

Generate a symbolic program capable of
answering the question.

Allowed operations:
add  sub  mul  div
percentage  percentage_change

Return only JSON:
{ "variables": { },
  "steps": [ { "name": "", "op": "",
               "args": [] } ],
  "unit": "" }
```

ACRÉSCIMO · SEMÂNTICA (TRADUZIDA E RESUMIDA)

```
add(a, b, ...) = a + b + ...
sub(a, b) = a - b
mul(a, b, ...) = a * b * ...
div(a, b) = a / b
percentage(part, whole) = part / whole
percentage_change(old, new)
    = (new - old) / old
value(a) = a   (valor lido do contexto)

Rules:
- variables: números do contexto
- args: variável, passo anterior
  ou constante
- nomes de passos ≠ nomes de variáveis
- último passo chamado "answer"
- percentuais como fração (25% -> 0.25)
```

O documento lista as operações, mas não define argumentos nem convenções. A semântica foi acrescentada (versão 2) depois da análise da primeira rodada: operação value para consultas, soma com vários termos e percentuais como fração.

E2

EXEMPLOS DO PLANNER E PROMPT DO EXECUTOR

Quatro exemplos curtos e um executor sem contexto

EXEMPLOS DO PLANNER (RESUMIDOS)

```
1 · consulta: "net revenue in 2019?"
  value(net_revenue_2019)

2 · soma: "combined total of the three
  segments?"
  add(segment_a, segment_b, segment_c)

3 · variação: "Revenue increased from 120
  to 150. Percentage increase?"
  percentage_change(old_value, new_value)

4 · proporção: "What portion of total
  expenses was R&D?"
  percentage(rd, total_expenses)
```

O exemplo 3 é o do documento de ablação, adaptado para percentage_change e resultado em fração. Os exemplos entram por padrão (INCLUDE_PLANNER_EXAMPLE = True).

PROMPT DO EXECUTOR (ÍNTEGRA; JSON COMPACTADO)

```
You are a symbolic program executor.

Execute the program below exactly as
written, one step at a time, in order.
Do not change the program and do not
use any outside information.

[semântica das operações]

Return only JSON:
{ "step_results": {"<step name>": <number>},
  "answer": <number> }

PROGRAM:
{program}
```

E2

AS CHAMADAS AO LLM

Dois agentes AutoGen novos para cada pergunta

BUILD_AGENTS E RUN_POT (SIMPLIFICADO)

```
planner = AssistantAgent(
    name="PoT_Planner",
    system_message=SYSTEM_PERSONA,
    llm_config=_base_llm_config(0.2), ...)

executor = AssistantAgent(
    name="LLM_Executor",
    system_message=SYSTEM_PERSONA,
    llm_config=_base_llm_config(0.2), ...)

# 1) plano
raw = planner.generate_reply(
    [{"role": "user",
      "content": build_planner_prompt(row)}])
# 2) execução (se o plano for JSON válido)
raw = executor.generate_reply(
    [{"role": "user",
      "content": build_executor_prompt(plan)}])
```

- **Mesma configuração** dos agentes do E0 e do E1: llama3:8b, temperatura 0,2, sem cache.
- **198 chamadas:** em 2 perguntas o plano não veio em JSON válido e o Executor não foi chamado.
- **Latência:** 20,4 s em média, 14,0 s na mediana. Na linha 65 o Executor gerou 20.551 tokens e levou 515 s.
- **Tokens:** 2.837 por pergunta, o dobro do E1; o Executor escreve muito texto além do JSON.

E2

DO PROGRAMA AO NÚMERO

Três leituras: o plano, a referência e o Executor

1. **Plano**
   o último JSON da resposta do Planner vira variables + steps + unit (normalize_plan)

2. **Referência Python**
   execute_program roda o plano; o resultado só serve para medir o plano

3. **Resposta do Executor**
   o "answer" do JSON do Executor; se falhar, a extração de texto livre do E0

4. **Categoria**
   compara plano, referência e resposta com o gabarito

Leitura do Executor	Respostas
json	93
json_sem_answer	4
sem plano (Executor não chamado)	2
fallback (texto livre)	1

Categorias de cada pergunta

correto · plano_invalido (não executa) · plano_errado (executa e dá outro número) · erro_execucao (plano certo, Executor errou) · correto_por_acaso.

E2

CRITÉRIO DE ACERTO

Dois critérios: estrito e com escala percentual

EM estrito · _answers_match

Certo se |resposta − gabarito| ≤ 1% × max(1, |gabarito|).
Ou seja: erro de até 1% do gabarito, ou até 0,01 quando o gabarito é menor que 1.

EM com escala percentual

Mesma regra; nas perguntas de percentual aceita também gabarito × 100 ou ÷ 100. O ConvFinQA guarda 36,93% como 0,3693.

- **No E2 os dois critérios quase coincidem:** 33% contra 32%. Só a linha 62 muda de categoria.
- **Motivo:** a semântica do Planner já pede percentuais como fração, a convenção do dataset. O problema de escala do E0 e do E1 praticamente desaparece.
- **Critério principal da ablação:** o EM com escala percentual; o estrito é a verificação de robustez.
- **As categorias do script** (plano_errado, erro_execucao…) usam o critério estrito.

E2

MÉTRICAS UTILIZADAS

As do E0/E1 e quatro novas sobre o plano

EM e IC de Wilson

% de perguntas certas (estrito e com escala) e a faixa provável do valor real.

MAE e erro relativo

Média de |resposta − gabarito|, absoluta e relativa, só em pares numéricos.

MSE e RMSE

Média dos erros ao quadrado e sua raiz. Penalizam muito os erros grandes.

Unit accuracy heurística

Em perguntas com unidade no texto, resposta a menos de 50% do gabarito.

Tokens, latência e custo

Das duas chamadas, somadas por pergunta; custo hipotético em API paga.

Plano válido e executável

% de planos em JSON válido e % que a referência Python consegue executar.

Plan Accuracy objetiva

% de perguntas cujo plano, executado pela referência, bate com o gabarito.

Execution Fidelity

Entre os planos executáveis, % em que o Executor chegou ao mesmo número da referência.

Decomposição dos erros

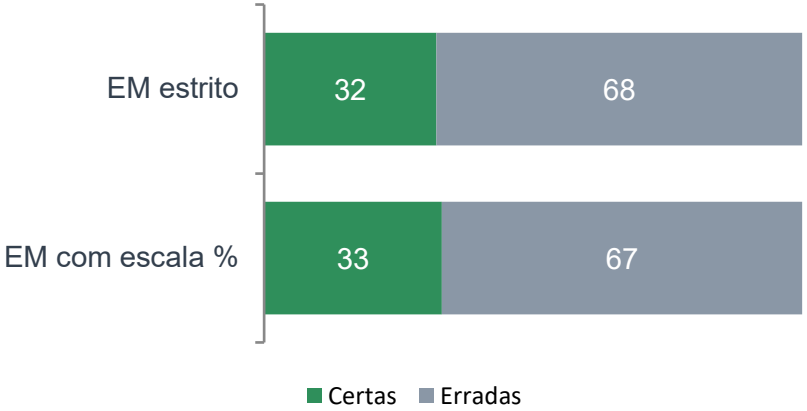
Cada pergunta: correto, plano inválido, plano errado ou erro de execução.

Em destaque, as métricas novas do E2. Kappa e Qui-Quadrado ficam no notebook de comparação E0–E7.

E2

RESULTADOS DO E2

33 acertos em 100 perguntas



Métrica	Valor [IC 95%]
EM com escala percentual	33% [24,6% – 42,7%]
EM estrito	32% [23,7% – 41,7%]
Perguntas de percentual certas	8 de 24
Demais perguntas certas	25 de 76
Unit accuracy heurística	43,3% (n = 90)
MAE (n = 94)	210.920,2
RMSE	1.390.954,2
Erro relativo médio	8.516.422%

198
chamadas ao LLM

2.036 s
latência total (20,4 s por pergunta)

284 mil
tokens (79% de entrada)

Custo hipotético em API paga: US$ 0,016 (Llama 3.1 8B na Groq) ou US$ 0,070 (GPT-4o mini). Execução real: local, sem custo de API.

E2

QUALIDADE DO PLANO

O plano quase sempre roda, mas raramente acerta

98%

planos em JSON válido

94%

planos executáveis

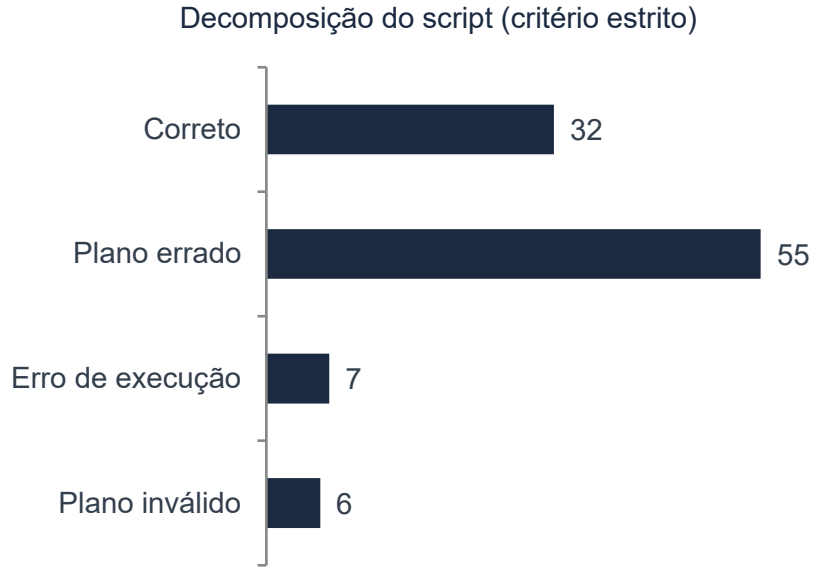
39%

Plan Accuracy: planos que levam ao gabarito

77%

Execution Fidelity: Executor fiel ao plano (n = 90)

Se o Executor fosse perfeito, o E2 acertaria 39%: a execução pelo LLM custou 7 pontos, e o plano custou todo o resto.



Planos não executáveis: argumento inexistente (3), JSON inválido (2), divisão por zero (1). Correto por acaso: nenhum.

E2

COMPARAÇÃO COM O E1

O programa custou 29 perguntas e ganhou 7

	E2 acertou	E2 errou
E1 acertou	26	**29**
E1 errou	**7**	38

McNemar da comparação E0–E7: 29 × 7 dá p (Holm) = 0,003. É a única passagem entre experimentos consecutivos com diferença significativa.

−22

pontos percentuais em relação ao E1

Por que as 29 foram perdidas	Perguntas
Operação errada (variação % no lugar de diferença)	**9**
Consulta direta virou conta	**7**
Valor errado do relatório	**5**
Pergunta de continuação	**4**
Erro do Executor (plano certo)	**2**
Plano inválido	**1**
Fórmula ou estrutura errada	**1**

16 das 29 perdas vêm da escolha da operação, e não da extração de valores.

E2

ANÁLISE DOS ERROS

As 67 perguntas erradas, por motivo provável



Operação errada · 14

Diferença, soma ou razão calculadas como percentage_change.

Consulta virou conta · 10

A pergunta pedia um valor que já estava nas variáveis, e o plano fez uma conta.

Continuação · 15 · Valor errado · 11

Os mesmos problemas do E0 e do E1: histórico e leitura do relatório.

Executor · 7 · Plano inválido · 4

Plano certo e conta errada, ou plano que não executa.

Mais: fórmula ou estrutura errada (4), sinal ou ordem (1) e gabarito atípico (1). Classificação feita lendo pergunta, plano, referência e resposta.

O Planner abusa de percentage_change

29 planos usam percentage_change

12 eram perguntas de percentual

3 desses planos acertaram

Linha	Pergunta	Programa gerado	Gabarito	Resultado
44	what was the change in net revenue from 2006 to 2007?	`percentage_change(net_revenue_2006, net_revenue_2007)`	20,8	0,04463
93	combined, what was the value of tax benefits realized from option exercises under all incentive plans for 2014 and 2013?	`percentage_change(tax_benefits_2013, tax_benefits_2014)`	64	0,06452
87	and throughout the precedent year, what was the decline in containerboard sales volume to external domestic and export customers, in tons?	`percentage_change(volume_2002, volume_2003)`	32000	-0,06709
70	what was the value in 2013?	`percentage_change(fair_value_2013, fair_value_2014)`	5,27	0,08918
95	what was the amount in received cash dividends in the year of 2010?	`percentage_change(dividends_2010, dividends_2011)`	71	0,09859

E2

PERGUNTAS DE CONTINUAÇÃO · 15 PERGUNTAS

O programa não resolve a dependência do histórico

Linha	Pergunta	O que era pedido	Gabarito	Resposta
52	what about the total including 2007?	2009 + 2008 + 2007 (o turno anterior somou dois anos)	102964	76066
78	and what was it in 2007?	o valor de 2007 (o de 2008 era 105)	40	105
92	and what was it in 2016?	o valor de 2016 (o de 2017 era 34,5)	26,4	34,5
46	so what was the percentage change during this time?	910 ÷ 510 (net change ÷ 2008)	1,78431	3,784
32	and how much does that change represent in relation to this total?	101 ÷ 728 (variação ÷ total)	0,13874	101
60	what is the percent change times 100?	variação percentual × 100	1,47092	-0,0165

Mesmo número do E1 (15). Em perguntas como "and what was it in 2007?", o Planner copia para as variáveis o valor do turno anterior em vez de buscar o novo ano no relatório.

O que a calculadora do E3 pode corrigir

Linha	Plano (resultado da referência)	Gabarito	Executor
9	`percentage_change(510, 1420) = 1,784`	1,78431	0,348
23	`sub(978,4, 998,7) = −20,3`	-20,3	0,0274
56	`sub(3859, 4822) = −963`	-963	963
57	`percentage_change(100, 285,81) = 1,8581`	1,8581	0,18581
88	`sub(5807,6, 5625,6) = 182`	182	1182

Com uma calculadora perfeita e os mesmos planos, o E2 iria de 33% para até 40%: o plano continua sendo o gargalo.

Erro do Executor · 7

Plano certo, conta errada: 910 ÷ 510 virou 0,348 (linha 9), −963 virou 963, 182 virou 1182. Na linha 2 o Executor não devolveu número.

Plano inválido · 4

Expressões dentro das variáveis ("205 * 1.23"), argumentos escritos como objetos ou referências a variáveis que não existem (linhas 4, 14, 21 e 49).

E2

DEMAIS CATEGORIAS · 17 PERGUNTAS

Leitura do relatório, fórmulas, sinal e gabarito

D

Valor errado do relatório · 11

Linha, item ou escala errados. Ex.: linha 96, valores em milhões (2500, 6870) para um gabarito em bilhões (4,37); linha 6, o mesmo valor no numerador e no denominador.

E

Fórmula ou estrutura · 4

Média feita como subtração (linha 55), soma de itens errados (66). Na linha 40 o passo certo foi calculado, mas a resposta apontou para uma variável zerada.

B

Sinal ou ordem · 1

Linha 79: sub(2019, 2020) em vez de sub(2020, 2019): 190 em vez de −190.

F

Gabarito atípico · 1

Linha 5: o relatório diz 2,2 anos e o gabarito, 2,1. A linha 4, atípica nos outros experimentos, aqui caiu em plano inválido.

E2

APÊNDICE 1/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
22	what was the change in r&d expenses from the year of 2016 to 2017, in millions?	12	0,052	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,052)
26	and what was the change in value of that stock considering the original amount invested…	227,11	2,2711	**Operação errada**	Pedia 327,11 − 100; usou percentage_change (2,27)
36	in that same period, what was the change in the total of current liabilities?	-42,8	0,0066	**Operação errada**	Usou ativos em vez de passivos e calculou percentual
39	what was the variation in the value of the fidelity national information services inc ….	57,38	0,5738	**Operação errada**	Pedia 157,38 − 100; usou percentage_change (0,5738)
43	what is the ratio of the value of freight revenue from the automotive group, 2012 to 2011?	1,19669	0,1934	**Operação errada**	Pedia a razão 2012/2011; usou percentage_change (0,197)
44	what was the change in net revenue from 2006 to 2007?	20,8	0,0414	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,045)
51	what was the change in value of the wti crude oil benchmark from 2009 to 2011?	33,02	0,5335	**Operação errada**	Pedia a variação em US$/barril; usou percentage_change (0,53)
54	what is the change in value of intrinsic value from 2016 to 2018?	-9	-0,5	**Operação errada**	Pedia 9 − 18; usou percentage_change (−0,5)
58	and only from 2011 to 2012, what was the change in the company 2019s cash, cash equival…	28,3	-0,514	**Operação errada**	Aplicou percentage_change sobre uma variável zerada (divisão por zero)
75	what is the amount lost from the bond authorization to the withdrawn for brentwood tenn…	2,7	0,965	**Operação errada**	Pedia 78,0 − 75,3; usou percentage (0,965)

E2

APÊNDICE 2/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
82	what was the change in net revenue between the two years?	-31,9	-0,0322	**Operação errada**	Pedia a variação em US$; usou percentage_change (−0,032)
85	so by how much did this value change over these years?	20,8	0,0446	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,045)
87	and throughout the precedent year, what was the decline in containerboard sales volume …	32000	0,0717	**Operação errada**	Pedia a queda em toneladas; usou percentage_change (−0,067)
93	combined, what was the value of tax benefits realized from option exercises under all i…	64	0,0645	**Operação errada**	Pedia a soma 33 + 31; usou percentage_change (0,065)
11	what is the value of the investment in 2014?	144	vazio	**Consulta virou conta**	Pedia o valor de 2014; subtraiu 2016 − 2014
15	and the specific value for 2008 again?	36836	vazio	**Consulta virou conta**	Pedia o valor de 2008; subtraiu 2009 − 2008 (o valor estava nas variáveis)
19	and what was the total of benefits obligations in 2018, also in millions?	31	-0,0123	**Consulta virou conta**	Pedia o total de 2018; calculou percentage_change
25	what was the ccg operating income in 2016?	10646	13216	**Consulta virou conta**	Pedia a receita de 2016 (10.646, nas variáveis); montou uma soma de vários itens
34	and what was that dividend yield in 2017?	3,573	0,0664	**Consulta virou conta**	Pedia o dividend yield de 2017 (3,573, nas variáveis); calculou percentage_change
68	what was the balance in 2005?	46	30	**Consulta virou conta**	Pedia o saldo de 2005; montou uma conta com os lançamentos

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
70	what was the value in 2013?	5,27	0,089	**Consulta virou conta**	Pedia o valor de 2013 (5,27, nas variáveis); calculou percentage_change
77	what was the value of outstanding commercial papers in 2007?	2,36	0,093	**Consulta virou conta**	Pedia o valor de 2007 (2,36, nas variáveis); calculou percentage_change
89	what was the total interest income in 2012?	29,5	0,7	**Consulta virou conta**	Pedia a receita de juros de 2012 (29,5, nas variáveis); subtraiu 2013 − 2012
95	what was the amount in received cash dividends in the year of 2010?	71	0,0986	**Consulta virou conta**	Pedia o valor de 2010 (71, nas variáveis); calculou percentage_change
10	and what was that percentage representation in the previous year, in 2011?	0,52288	0,406	**Pergunta de continuação**	Pedia o percentual de 2011; usou os valores de 2012 do turno anterior
24	and the percentage change of this value?	0,97734	34,5	**Pergunta de continuação**	Pedia a variação percentual do valor anterior; fez só a diferença (−34,5)
27	what is the change in value of this investment?	67,45	181,27	**Pergunta de continuação**	Pedia a variação do investimento do histórico; usou outros anos (181,27)
32	and how much does that change represent in relation to this total?	0,13874	101	**Pergunta de continuação**	Pedia 101 ÷ 728; repetiu a variação (101)
46	so what was the percentage change during this time?	1,78431	3,784	**Pergunta de continuação**	Pedia 910 ÷ 510 do histórico; usou −510 como valor inicial
47	what is that value less 1?	0,044	1127587	**Pergunta de continuação**	Pedia 1,044 − 1 do turno anterior; devolveu um saldo (1.127.587)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
48	and what was that for the decrease in interest rates?	82,5	-91,3	**Pergunta de continuação**	Pedia o efeito da queda de juros; repetiu o do aumento (−91,3)
52	what about the total including 2007?	102964	76066	**Pergunta de continuação**	Pedia 2009 + 2008 + 2007; somou só 2009 + 2008
60	what is the percent change times 100?	1,47092	-0,0165	**Pergunta de continuação**	Pedia a variação × 100 (1,47); não multiplicou e trocou o sinal
61	and what is this representation as a portion of the 2009 total?	0,97656	0,5	**Pergunta de continuação**	Pedia 1,5625 ÷ 1,6; calculou percentage_change na ordem inversa
65	so what was the percentage change during this time?	0,21795	vazio	**Pergunta de continuação**	Pedia a variação percentual das taxas do histórico; usou outros valores
76	what about percentage change?	28,571	2	**Pergunta de continuação**	Pedia a variação percentual; repetiu a diferença do turno anterior (2)
78	and what was it in 2007?	40	105	**Pergunta de continuação**	Pedia o valor de 2007; repetiu o de 2008 do histórico (105)
80	and what is the percentage this change represents of those losses in 2005?	0,70705	-0,2174	**Pergunta de continuação**	Pedia 71,2 ÷ perdas de 2005; calculou percentage_change entre anos
92	and what was it in 2016?	26,4	34,5	**Pergunta de continuação**	Pedia o valor de 2016; repetiu o de 2017 do histórico (34,5)
6	what is the value of operating leases over the total minimum payments?	0,68368	1	**Valor errado do relatório**	Atribuiu o mesmo valor (3430) ao numerador e ao denominador

E2

APÊNDICE 5/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
13	what about the ending accrued warranty and related costs in 2007?	230	143	**Valor errado do relatório**	Montou o saldo final de 2007 com lançamentos de anos errados
17	what was the 2008 value?	1,74	337,6	**Valor errado do relatório**	Pegou o lucro líquido de 2008 (337,6); o gabarito é outro item (1,74)
59	how many shares were repurchased during 2017?	3,4	1,8	**Valor errado do relatório**	Informou 1,8 mi de ações; gabarito 3,4 mi
69	in the year of 2018, what was the total net cash used?	2054	1665,8	**Valor errado do relatório**	Combinou linhas erradas da demonstração de caixa
71	and the percentage of the maturities that are part of the total maturities in 2008?	0,05768	0,9999	**Valor errado do relatório**	Usou totais de vencimentos errados (razão ≈ 1)
73	what is the sum of the total minimum lease payments for both operating and capital leases?	7807	845	**Valor errado do relatório**	Somou só os valores de 2009, não os totais
81	combined, what was the total net operating loss that must be utilized before expiration…	32,2	-0,9674	**Valor errado do relatório**	Somou itens errados dos prejuízos fiscais
84	what was the balance of unpaid losses in the beginning of 2008?	7603	24241	**Valor errado do relatório**	Pegou o saldo líquido de 2008 (24.241) em vez de 7.603
91	what was the total amount of resale agreements in 2008, in millions?	20800	200265	**Valor errado do relatório**	Pegou a linha da tabela (200.265) em vez de 20.800
96	what was the change in value of cds that were excluded between 2013 and 2014?	4,37	4370	**Valor errado do relatório**	Valores em milhões (2500, 6870) para um gabarito em bilhões (4,37)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
2	what were the total number of shares purchased?	4823020	vazio	**Erro do Executor**	Plano certo (4.823.020); o Executor não devolveu número
9	what percentage change does this represent?	1,78431	0,348	**Erro do Executor**	Plano certo (1,784); o Executor devolveu 0,348
23	what was the net change in revenues from 2003 to 2004?	-20,3	0,0274	**Erro do Executor**	Plano certo (−20,3); o Executor devolveu 0,0274
56	what was the net change in value?	-963	963	**Erro do Executor**	Plano certo (−963); o Executor trocou o sinal (963)
57	what return rate does this represent?	1,8581	0,18581	**Erro do Executor**	Plano certo (1,8581); o Executor devolveu 0,18581
88	what is the net change in the total consolidated revenues from 2011 to 2012?	182	1182	**Erro do Executor**	Plano certo (182); o Executor devolveu 1182
98	what is the percent change?	-0,17266	0,82345	**Erro do Executor**	Plano certo (−0,17266); o Executor devolveu 0,823
4	considering the amount of those 2003 earnings, what can be concluded to have been those…	20452,85	vazio	**Plano inválido**	JSON inválido: expressões ("205 * 1.0023") dentro das variáveis
14	what is the difference between 100% and that increase?	99,77	vazio	**Plano inválido**	JSON inválido: expressões ("205 * 1.23") dentro das variáveis
21	and what is, in millions, the average tax benefit between those three years?	26	78	**Plano inválido**	Argumentos escritos como objetos ({"name": …}) em vez de nomes

E2

APÊNDICE 7/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
49	and what was it in 2007?	28,37	0,132	**Plano inválido**	Argumento que não existe entre as variáveis
40	what is the total value of proceeds from the issuance of employee options during februa…	11556103,23	11530,443	**Fórmula ou estrutura**	Multiplicou certo, mas a resposta apontou para a variável "proceeds" = 0
45	what is the percent of shares not related to post-merger services?	0,15116	6876330	**Fórmula ou estrutura**	Pedia um percentual; subtraiu valores absolutos
55	what is the average balance for these years?	8,5	-866	**Fórmula ou estrutura**	Pedia a média; subtraiu 2014 − 2013
66	what is the net change?	95,6	2762,9	**Fórmula ou estrutura**	Pedia 2885,6 − 2790,0; somou quatro itens
79	what is the net change in operating leases from 2019 to 2020?	-190	190	**Sinal / ordem**	Subtraiu 2019 − 2020 (ordem inversa): 190 em vez de −190
5	and what is the weighted-average period over which this cost will be recognized, in years?	2,1	2,2	**Gabarito atípico**	Texto diz 2,2 anos; gabarito 2,1 (possível divergência)

CONCLUSÕES E RECOMENDAÇÕES

O programa simbólico derrubou o acerto de 55% para 33%, e o problema está no plano

O que o E2 mostra

- 33% de acerto (IC 25–43%), −22 pontos em relação ao E1, com diferença significativa.
- O plano quase sempre roda (94%), mas só 39% levam ao gabarito.
- O Executor custa 7 pontos; o E3 pode recuperá-los.

Onde o plano erra

- Escolha da operação: percentage_change em diferenças, somas e consultas (24 perguntas).
- Continuação e leitura do relatório, como no E0 e no E1 (26).
- Custo alto: 2 chamadas, 20 s e 2.837 tokens por pergunta.

O que testar

- Um exemplo de diferença absoluta ("change" → sub).
- Regra: percentage_change só quando a pergunta pedir percentual.
- Manter a mudança igual de E2 a E7, para não quebrar a ablação.