E3

DOCUMENTAÇÃO DO SCRIPT · PoT + CALCULADORA

Experimento E3: o LLM só planeja; a conta é feita por uma calculadora

Como o script funciona, quais prompts usa, como mede o resultado e por que errou 64 das 100 perguntas

Notebook E3_PoT_Calculator_METRICAS_Amostra_v2 · ConvFinQA (100 perguntas) · llama3:8b via Ollama + AutoGen

E3

OBJETIVO

Separar planejamento de execução ajuda?

O E3 mantém o Planner do E2 e troca só quem executa o programa: sai o LLM Executor, entra uma calculadora Python determinística. O LLM não faz mais nenhuma conta. A pergunta do experimento é quanto do erro do PoT vem da execução e quanto vem do plano.

Igual ao E2

Modelo, temperatura 0,2, persona, montagem da entrada, prompt do Planner (conferido caractere por caractere), semântica das operações e critério de acerto.

36%

EM com escala percentual (E2: 33%)

36%

EM estrito (E2: 32%)

92%

planos executáveis

1

chamada ao LLM por pergunta (E2: 2)

7,3 s

latência média (E2: 20,4 s)

1.964

tokens médios por pergunta (E2: 2.837)

E3

ESTRUTURA DO SCRIPT

Um notebook, três células, dez blocos de código

1 **Célula 1**
Imprime data e hora de início

2 **Célula 2**
Todo o experimento (detalhado ao lado)

3 **Célula 3**
Imprime data e hora de término

Os blocos em destaque mudaram em relação ao E2.

Configuração + REUSE_PLANS_FROM_CSV (desligado nesta rodada)

Prompts Planner idêntico ao E2; sem prompt de Executor

Estrutura de dados PoTCalcResult: plano, calc_status, categoria

Utilitários leitura de JSON, _to_float, _answers_match

Métricas as do E2, sem as do LLM Executor

Calculadora normalize_plan e execute_program (agora dá a resposta)

AutoGen um só agente: PoT_Planner

Montagem da entrada split_dialogue, build_fields (igual ao E0–E2)

Fluxo E3 build_planner_prompt, load_reused_plans, run_pot_calc

main() loop, CSVs de saída, resumo com decomposição dos erros

E3

DIAGRAMA DO FLUXO

Um agente planeja; a calculadora executa



Uma única chamada ao LLM por pergunta. Se o plano não vier em JSON válido ou não puder ser executado, não há resposta e a pergunta conta como erro.

E3

COMO A BASE É RECEBIDA

A mesma entrada do E0 ao E2

O CSV (100 linhas)

text: relatório financeiro (texto + tabela HTML) seguido do diálogo "Question: … Answer: … Question: …".
output: gabarito numérico.
Média de 4.423 caracteres por linha.

Quem recebe o quê

Planner: os quatro blocos (QUESTION, TEXT, TABLE, HISTORY).
Calculadora: só o programa, como o Executor do E2.
64 das 100 linhas têm histórico.

EXEMPLO REAL · LINHA 9 DO CSV, JÁ DIVIDIDA

```
QUESTION:
what percentage change does this represent?

TEXT:
corporate/other includes global staff
functions ( includes finance , risk , ...
[3.198 caracteres de relatório e tabela]

TABLE:
(not provided separately -- any table is
included in the TEXT block)

HISTORY:
Question: what are the total operating
  expenses in 2009?     Answer: 1420.0
Question: what about in 2008?  Answer: 510.0
Question: what is the net change? Answer: 910.0
```

E3

PROMPT DO PLANNER

O mesmo do E2, caractere por caractere

DOCUMENTO DE ABLAÇÃO · OPERAÇÕES E JSON COMPACTADOS

```
You are a financial reasoning planner.

Do not calculate the final answer.

Generate a symbolic program capable of
answering the question.

Allowed operations:
add  sub  mul  div
percentage  percentage_change

Return only JSON:
{ "variables": { },
  "steps": [ { "name": "", "op": "",
               "args": [] } ],
  "unit": "" }
```

O QUE VEM DEPOIS DO TEXTO DO DOCUMENTO

```
+ semântica das operações
  add, sub, mul, div, value,
  percentage(part, whole) = part / whole
  percentage_change(old, new)
      = (new - old) / old

+ regras: variáveis numéricas, nomes de
  passos ≠ nomes de variáveis, último
  passo "answer", percentuais como fração

+ 4 exemplos: consulta (value), soma
  (add), variação (percentage_change),
  proporção (percentage)

+ QUESTION / TEXT / TABLE / HISTORY
```

Sem prompt de Executor: a execução não passa mais por um LLM. O detalhamento completo da semântica e dos exemplos está na documentação do E2 e nas notas deste slide.

E3

A CALCULADORA

Executa o programa exatamente como está escrito

EXECUTE_PROGRAM · PSEUDOCÓDIGO

```
para cada passo do programa:
  confere a operação e o nº de argumentos
  para cada argumento:
    se é variável        -> valor da variável
    senão, passo anterior -> resultado dele
    senão, número         -> constante
  resultado[passo] <- operação(args)

resposta <- resultado["answer"]
          (ou o do último passo)
```

Regra de prioridade: quando um passo tem o mesmo nome de uma variável, a calculadora usa a variável. Essa regra causou um erro nesta rodada (slide 18).

Operação	Argumentos	Resultado
`value`	1	a
`add · mul`	2 ou mais	soma · produto
`sub · div`	2	a – b · a ÷ b
`percentage`	2	part ÷ whole
`percentage_change`	2	(new – old) ÷ old

Falhas registradas (calc_status)

op_invalida · aridade_invalida · arg_nao_resolvido · divisao_por_zero · variavel_nao_numerica · sem_steps · plano_json_invalido. Nesses casos não há resposta.

E3

A CHAMADA AO LLM

Um agente AutoGen novo para cada pergunta

BUILD_AGENTS E RUN_POT_CALC (SIMPLIFICADO)

```
planner = AssistantAgent(
    name="PoT_Planner",
    system_message=SYSTEM_PERSONA,
    llm_config=_base_llm_config(0.2),
    human_input_mode="NEVER",
    max_consecutive_auto_reply=1,
    code_execution_config=False)

raw = planner.generate_reply(
    [{"role": "user",
      "content": build_planner_prompt(row)}])

plan = normalize_plan(
    _parse_json_response(raw))
answer, status = execute_program(plan)
```

- **Mesma configuração** do Planner do E2: llama3:8b, temperatura 0,2, sem cache.
- **100 chamadas** (uma por pergunta), contra 198 no E2.
- **Latência:** 7,3 s em média, 6,5 s na mediana, no máximo 41 s. Sem o Executor, desaparecem as respostas longas que chegavam a 515 s.
- **Tokens:** 1.964 por pergunta; 91% são a entrada (o contexto do relatório).

E3

DO PROGRAMA AO NÚMERO

A resposta é o resultado da calculadora

1 **Plano**
o último JSON da resposta do Planner vira variables + steps + unit

2 **Execução**
a calculadora roda o programa; ou devolve um número, ou um motivo de falha

3 **Comparação**
o número é comparado com o gabarito (estrito e com escala percentual)

4 **Categoria**
correto · plano_invalido · plano_errado

Resultado da calculadora	Perguntas
número (calc_status = ok)	92
plano em JSON inválido	4
argumento não resolvido	3
aridade inválida	1

Sem categorias de execução

erro_execucao e correto_por_acaso não existem mais: a resposta é a própria execução do plano, então Plan Accuracy = EM.

E3

CRITÉRIO DE ACERTO

Dois critérios: estrito e com escala percentual

EM estrito · _answers_match

Certo se |resposta − gabarito| ≤ 1% × max(1, |gabarito|). Ou seja: erro de até 1% do gabarito, ou até 0,01 quando o gabarito é menor que 1.

EM com escala percentual

Mesma regra; nas perguntas de percentual aceita também gabarito × 100 ou ÷ 100. O ConvFinQA guarda 36,93% como 0,3693.

- **No E3 os dois critérios coincidem:** 36% nos dois. Nenhuma pergunta depende da tolerância de escala.
- **Motivo:** a calculadora aplica a semântica em fração, a mesma convenção do dataset.
- **Perguntas de percentual:** 11 de 24 certas (E2: 8; E1: 10). Demais perguntas: 25 de 76.
- **Critério principal da ablação:** o EM com escala percentual; o estrito é a verificação de robustez.

E3

MÉTRICAS UTILIZADAS

As do E2, sem as do LLM Executor

EM e IC de Wilson

% de perguntas certas (estrito e com escala) e a faixa provável do valor real.

MAE e erro relativo

Média de |resposta − gabarito|, absoluta e relativa, só em pares numéricos.

MSE e RMSE

Média dos erros ao quadrado e sua raiz. Penalizam muito os erros grandes.

Unit accuracy heurística

Em perguntas com unidade no texto, resposta a menos de 50% do gabarito.

Tokens, latência e custo

Da única chamada ao Planner; custo hipotético em API paga.

Plano válido e executável

% de planos em JSON válido e % que a calculadora consegue executar.

Plan Accuracy objetiva

% de planos que levam ao gabarito. No E3 é igual ao EM, por construção.

Decomposição dos erros

Cada pergunta: correto, plano inválido ou plano errado.

Removidas

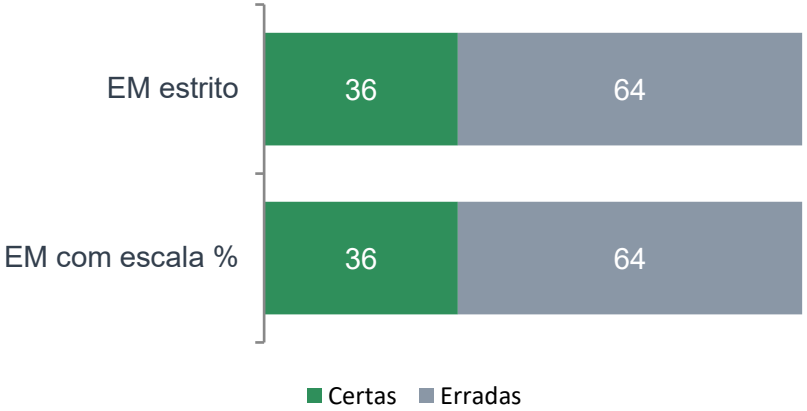
Execution Fidelity e validade do JSON do Executor: não há mais LLM Executor.

Em destaque, as métricas do plano. Kappa e Qui-Quadrado ficam no notebook de comparação E0–E7.

E3

RESULTADOS DO E3

36 acertos em 100 perguntas



Métrica	Valor [IC 95%]
EM com escala percentual	36% [27,3% – 45,8%]
EM estrito	36% [27,3% – 45,8%]
Perguntas de percentual certas	11 de 24
Demais perguntas certas	25 de 76
Unit accuracy heurística	44,4% (n = 90)
MAE (n = 92)	138.375,6
RMSE	1.207.565,9
Erro relativo médio	115.128%

100
chamadas ao LLM

733,9 s
latência total (7,3 s por pergunta)

196 mil
tokens (91% de entrada)

Custo hipotético em API paga: US$ 0,010 (Llama 3.1 8B na Groq) ou US$ 0,037 (GPT-4o mini). Execução real: local, sem custo de API.

E3

COMPARAÇÃO COM O E2

A calculadora ajuda, mas o plano varia entre rodadas

	E3 acertou	E3 errou
E2 acertou	27	**6**
E2 errou	**9**	58

McNemar da comparação E0–E7: 9 × 6 dá p (Holm) = 1,00. A diferença de +3 pontos não é significativa.

Só 35 planos são iguais aos do E2

Nesses 35, o E3 ganhou 2 (linhas 9 e 56, erros do Executor no E2) e não perdeu nenhum.

9 que o E3 ganhou

5 eram erros do LLM Executor no E2, corrigidos pela calculadora (2, 9, 56, 57, 98). As outras 4 (65, 66, 68, 82) vieram de planos diferentes gerados nesta rodada.

6 que o E3 perdeu

Todas por planos diferentes nesta rodada: consulta que virou conta (30, 99), variável errada (63), resposta apontando para uma variável zerada (0) e planos inválidos (62, 72).

E3

QUALIDADE DO PLANO

O plano continua sendo o gargalo

96%

planos em JSON válido (E2: 98%)

92%

planos executáveis (E2: 94%)

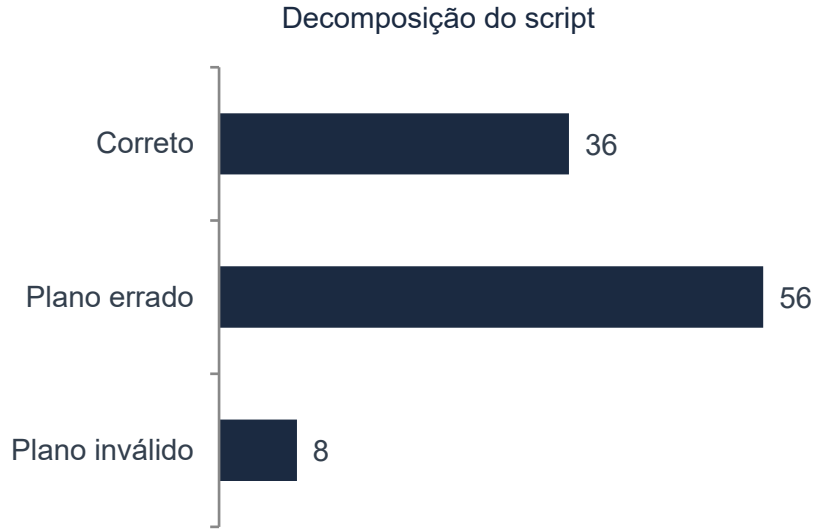
36%

Plan Accuracy = EM (E2: 39%)

30

planos com percentage_change (E2: 29)

A calculadora eliminou os erros de execução, mas o Planner desta rodada acertou um pouco menos planos do que o do E2. O resultado final quase não mudou.



Planos não executáveis: JSON inválido (4), argumento inexistente (3), aridade inválida (1).

E3

ANÁLISE DOS ERROS

As 64 perguntas erradas, por motivo provável



Continuação · 13 · Valor errado · 13

Os mesmos problemas do E0 ao E2: histórico e leitura do relatório.

Operação errada · 12 · Consulta virou conta · 12

Diferenças e consultas calculadas como variação percentual ou subtração.

Plano inválido · 8

JSON quebrado, argumentos aninhados ou que não existem.

Variável zerada · 3

Novo no E3: a conta foi feita, mas a resposta aponta para uma variável 0.

Mais: fórmula incompleta (2) e sinal ou ordem (1). Nenhum erro de execução: a calculadora faz exatamente o que o plano manda.

E3

OPERAÇÃO ERRADA E CONSULTA VIROU CONTA · 24

O mesmo abuso de percentage_change do E2

30
planos usam percentage_change

13
eram perguntas de percentual

7
desses planos acertaram

Linha	Pergunta	Programa gerado	Gabarito	Resultado
44	what was the change in net revenue from 2006 to 2007?	`percentage_change(net_revenue_2006, net_revenue_2007)`	20,8	0,04463
93	combined, what was the value of tax benefits realized from option exercises under all incentive plans for 2014 and 2013?	`percentage_change(tax_benefit_2013, tax_benefit_2014)`	64	0,06452
30	what was the tax benefit realized from option exercises under all incentive plans in 2014, in millions?	`percentage(tax_benefit_2014, cash_received_2014)`	33	0,15349
99	what was the balance of total ishares in 2013?	`sub(total_ishares_2013, total_ishares_2012)`	914372	161666
77	what was the value of outstanding commercial papers in 2007?	`percentage_change(cps_2007, cps_2008)`	2,36	0,09746

E3

PERGUNTAS DE CONTINUAÇÃO · 13 PERGUNTAS

O histórico continua sendo mal usado

Linha	Pergunta	O que era pedido	Gabarito	Resposta
52	what about the total including 2007?	2009 + 2008 + 2007	102964	75968
78	and what was it in 2007?	o valor de 2007 (o de 2008 era 105)	40	105
92	and what was it in 2016?	o valor de 2016 (o de 2017 era 34,5)	26,4	34,5
46	so what was the percentage change during this time?	910 ÷ 510 (net change ÷ 2008)	1,78431	-2,78431
32	and how much does that change represent in relation to this total?	101 ÷ 728 (variação ÷ total)	0,13874	728
47	what is that value less 1?	1,044 − 1 (razão do turno anterior)	0,044	103697

Em perguntas como "and what was it in 2007?", o Planner repete nas variáveis o valor do turno anterior em vez de buscar o novo ano. A calculadora não tem como corrigir isso: ela só executa o que recebe.

A calculadora não perdoa erros de formato

Linha	O que o plano fez	Gabarito	Resposta
0	add(52,4; 41) = 93,4 no passo step1, mas answer = value(total_balance), declarada como 0	93,4	0
88	passo revenue_change = 182, mas existe a variável revenue_change = 0, e ela tem prioridade	182	0
40	mul(opções, preço) no passo calculate_proceeds, mas answer = value(proceeds), declarada como 0	11556103,23	0

No E2 o LLM Executor "entendia" o que o plano queria e ignorava esses deslizes. A calculadora executa literalmente.

Plano inválido · 8

JSON quebrado por expressões ("205 * 1.23") ou argumentos aninhados (4, 14, 24, 45); sub com três argumentos (23); argumentos que não existem ou escritos como objetos (62, 72, 75).

A regra de prioridade

Na linha 88 a calculadora deu prioridade à variável zerada sobre o passo de mesmo nome. Invertendo a regra (o passo vence), a 88 passaria a acertar, e nenhum dos outros 6 planos com nomes repetidos mudaria.

E3

DEMAIS CATEGORIAS · 16 PERGUNTAS

Leitura do relatório, fórmulas e sinal

D

Valor errado do relatório · 13

Linha, item ou escala errados. Ex.: linha 63, pegou a variável de 2010 (369) em vez da de 2006 (100); linha 96, valores em milhões para um gabarito em bilhões.

E

Fórmula incompleta · 2

Médias sem a divisão: a linha 21 somou três anos (78) e não dividiu por 3; a linha 55 subtraiu em vez de tirar a média.

B

Sinal ou ordem · 1

Linha 79: sub(2019, 2020) em vez de sub(2020, 2019): 190 em vez de −190. O mesmo plano do E2.

E3

APÊNDICE 1/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
22	what was the change in r&d expenses from the year of 2016 to 2017, in millions?	12	0,06349	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,063)
26	and what was the change in value of that stock considering the original amount invested…	227,11	2,2711	**Operação errada**	Pedia 327,11 − 100; usou percentage_change (2,27)
36	in that same period, what was the change in the total of current liabilities?	-42,8	0,06665	**Operação errada**	Usou ativos em vez de passivos e percentage_change
39	what was the variation in the value of the fidelity national information services inc ….	57,38	0,5738	**Operação errada**	Pedia 157,38 − 100; usou percentage_change (0,5738)
43	what is the ratio of the value of freight revenue from the automotive group, 2012 to 2011?	1,19669	1,17219	**Operação errada**	Pedia a razão 2012/2011; usou percentage_change com valores errados
44	what was the change in net revenue from 2006 to 2007?	20,8	0,04463	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,045)
51	what was the change in value of the wti crude oil benchmark from 2009 to 2011?	33,02	0,53181	**Operação errada**	Pedia a variação em US$/barril; usou percentage_change (0,53)
54	what is the change in value of intrinsic value from 2016 to 2018?	-9	-0,5	**Operação errada**	Pedia 9 − 18; usou percentage_change (−0,5)
58	and only from 2011 to 2012, what was the change in the company 2019s cash, cash equival…	28,3	1,73493	**Operação errada**	Pedia a variação do caixa; usou percentage_change de outro item
85	so by how much did this value change over these years?	20,8	0,04463	**Operação errada**	Pedia a variação em US$; usou percentage_change (0,045)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
87	and throughout the precedent year, what was the decline in containerboard sales volume …	32000	-0,06709	**Operação errada**	Pedia a queda em toneladas; usou percentage_change (−0,067)
93	combined, what was the value of tax benefits realized from option exercises under all i…	64	0,06452	**Operação errada**	Pedia a soma 33 + 31; usou percentage_change (0,065)
11	what is the value of the investment in 2014?	144	54	**Consulta virou conta**	Pedia o valor de 2014; subtraiu 2019 − 2014
13	what about the ending accrued warranty and related costs in 2007?	230	0,09375	**Consulta virou conta**	Pedia o saldo de 2007; calculou diferença e percentual
15	and the specific value for 2008 again?	36836	28169	**Consulta virou conta**	Pedia o valor de 2008 (nas variáveis); subtraiu 2009 − 2008
19	and what was the total of benefits obligations in 2018, also in millions?	31	-0,03704	**Consulta virou conta**	Pedia o total de 2018; calculou percentage_change entre 2018 e 2019
25	what was the ccg operating income in 2016?	10646	31498	**Consulta virou conta**	Pedia a receita de 2016 (10.646, nas variáveis); somou vários itens
30	what was the tax benefit realized from option exercises under all incentive plans in 20…	33	0,15349	**Consulta virou conta**	Pedia o benefício de 2014 (33, nas variáveis); calculou percentage
34	and what was that dividend yield in 2017?	3,573	0,08704	**Consulta virou conta**	Pedia o yield de 2017 (3,573, nas variáveis); calculou percentage_change
70	what was the value in 2013?	5,27	0,08918	**Consulta virou conta**	Pedia o valor de 2013 (5,27, nas variáveis); calculou percentage_change

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
77	what was the value of outstanding commercial papers in 2007?	2,36	0,09746	**Consulta virou conta**	Pedia o valor de 2007 (2,36, nas variáveis); calculou percentage_change
89	what was the total interest income in 2012?	29,5	-4,8	**Consulta virou conta**	Pedia a receita de 2012 (29,5, nas variáveis); subtraiu 2013 − 2012
95	what was the amount in received cash dividends in the year of 2010?	71	7	**Consulta virou conta**	Pedia o valor de 2010 (71, nas variáveis); subtraiu 2011 − 2010
99	what was the balance of total ishares in 2013?	914372	161666	**Consulta virou conta**	Pedia o saldo de 2013 (914.372, nas variáveis); subtraiu 2013 − 2012
10	and what was that percentage representation in the previous year, in 2011?	0,52288	1,7339	**Pergunta de continuação**	Pedia o percentual de 2011; montou outra razão (1,73)
27	what is the change in value of this investment?	67,45	76,07	**Pergunta de continuação**	Pedia a variação do investimento do histórico; usou outros anos (76,07)
32	and how much does that change represent in relation to this total?	0,13874	728	**Pergunta de continuação**	Pedia 101 ÷ 728; devolveu o total (728)
46	so what was the percentage change during this time?	1,78431	-2,78431	**Pergunta de continuação**	Pedia 910 ÷ 510 do histórico; usou −510 como valor inicial
47	what is that value less 1?	0,044	103697	**Pergunta de continuação**	Pedia 1,044 − 1 do turno anterior; devolveu 103.697
48	and what was that for the decrease in interest rates?	82,5	-91,3	**Pergunta de continuação**	Pedia o efeito da queda de juros; repetiu o do aumento (−91,3)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
52	what about the total including 2007?	102964	75968	**Pergunta de continuação**	Pedia 2009 + 2008 + 2007; devolveu só 2009
60	what is the percent change times 100?	1,47092	-0,68985	**Pergunta de continuação**	Pedia a variação × 100 (1,47); montou outra conta (−0,69)
61	and what is this representation as a portion of the 2009 total?	0,97656	0,5625	**Pergunta de continuação**	Pedia 1,5625 ÷ 1,6; calculou percentage_change (0,5625)
76	what about percentage change?	28,571	2	**Pergunta de continuação**	Pedia a variação percentual; repetiu a diferença do turno anterior (2)
78	and what was it in 2007?	40	105	**Pergunta de continuação**	Pedia o valor de 2007; repetiu o de 2008 do histórico (105)
80	and what is the percentage this change represents of those losses in 2005?	0,70705	-2,18272	**Pergunta de continuação**	Pedia 71,2 ÷ perdas de 2005; calculou percentage_change entre anos
92	and what was it in 2016?	26,4	34,5	**Pergunta de continuação**	Pedia o valor de 2016; repetiu o de 2017 do histórico (34,5)
5	and what is the weighted-average period over which this cost will be recognized, in years?	2,1	7,1	**Valor errado do relatório**	Pegou o custo não reconhecido (7,1) em vez do prazo (2,2); gabarito 2,1
6	what is the value of operating leases over the total minimum payments?	0,68368	1	**Valor errado do relatório**	Atribuiu o mesmo valor (3430) ao numerador e ao denominador
17	what was the 2008 value?	1,74	319,5	**Valor errado do relatório**	Pegou o lucro líquido de 2008 (319,5); o gabarito é outro item (1,74)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
49	and what was it in 2007?	28,37	157,26	**Valor errado do relatório**	Somou itens errados da tabela de 2007 (157,26)
59	how many shares were repurchased during 2017?	3,4	1,8	**Valor errado do relatório**	Informou 1,8 mi de ações; gabarito 3,4 mi
63	what was the 2006 value?	100	369	**Valor errado do relatório**	Pegou a variável de 2010 (369) em vez da de 2006 (100)
69	in the year of 2018, what was the total net cash used?	2054	3176	**Valor errado do relatório**	Combinou linhas erradas da demonstração de caixa
71	and the percentage of the maturities that are part of the total maturities in 2008?	0,05768	1,00383	**Valor errado do relatório**	Usou totais de vencimentos errados (razão ≈ 1)
73	what is the sum of the total minimum lease payments for both operating and capital leases?	7807	845	**Valor errado do relatório**	Somou só os valores de 2009, não os totais
81	combined, what was the total net operating loss that must be utilized before expiration…	32,2	-4519,9	**Valor errado do relatório**	Montou a conta com itens errados (−4519,9)
84	what was the balance of unpaid losses in the beginning of 2008?	7603	24241	**Valor errado do relatório**	Pegou o saldo líquido de 2008 (24.241) em vez de 7.603
91	what was the total amount of resale agreements in 2008, in millions?	20800	200265	**Valor errado do relatório**	Pegou a linha da tabela (200.265) em vez de 20.800
96	what was the change in value of cds that were excluded between 2013 and 2014?	4,37	4370	**Valor errado do relatório**	Valores em milhões (2500, 6870) para gabarito em bilhões (4,37)

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
4	considering the amount of those 2003 earnings, what can be concluded to have been those…	20452,85	vazio	**Plano inválido**	JSON inválido: expressão ("205 * 1.23") dentro das variáveis
14	what is the difference between 100% and that increase?	99,77	vazio	**Plano inválido**	JSON inválido: expressão e nomes de operação dentro das variáveis
23	what was the net change in revenues from 2003 to 2004?	-20,3	vazio	**Plano inválido**	sub com três argumentos (aridade inválida)
24	and the percentage change of this value?	0,97734	vazio	**Plano inválido**	JSON inválido (argumentos com operações aninhadas)
45	what is the percent of shares not related to post-merger services?	0,15116	vazio	**Plano inválido**	JSON inválido; o plano subtraía ações em vez de calcular o percentual
62	and as of the last year of this period, what percentage of the aggregate borrowing capa…	0,32	vazio	**Plano inválido**	Argumento que não existe entre as variáveis
72	what was, then, the change over the year?	-1,9	vazio	**Plano inválido**	Argumentos escritos como objetos ({"value": …})
75	what is the amount lost from the bond authorization to the withdrawn for brentwood tenn…	2,7	vazio	**Plano inválido**	Argumentos escritos como passos aninhados
0	what was the total balance of letters of credit outstanding for the years of 2006 and 2…	93,4	0	**Resposta em variável zerada**	Somou certo (93,4), mas a resposta aponta para a variável total_balance = 0
40	what is the total value of proceeds from the issuance of employee options during februa…	11556103,23	0	**Resposta em variável zerada**	Multiplicou em outro passo; a resposta aponta para proceeds = 0

E3

APÊNDICE 7/7 · PERGUNTAS ERRADAS

Lista completa com o motivo provável

Linha	Pergunta	Gabarito	Resposta	Categoria	Motivo provável
88	what is the net change in the total consolidated revenues from 2011 to 2012?	182	0	**Resposta em variável zerada**	Passo revenue_change = 182 tem o nome de uma variável zerada; a calculadora usou a variável
21	and what is, in millions, the average tax benefit between those three years?	26	78	**Fórmula incompleta**	Pedia a média; somou sem dividir por 3 (78)
55	what is the average balance for these years?	8,5	-865	**Fórmula incompleta**	Pedia a média; subtraiu 2014 − 2013
79	what is the net change in operating leases from 2019 to 2020?	-190	190	**Sinal / ordem**	Subtraiu 2019 − 2020 (ordem inversa): 190 em vez de −190

CONCLUSÕES E RECOMENDAÇÕES

A calculadora corrigiu a conta e tornou o PoT mais barato, mas o plano continua limitando o resultado

O que o E3 mostra

- 36% de acerto (IC 27–46%), +3 pontos sobre o E2, sem significância.
- Nos 35 planos iguais aos do E2, a calculadora ganhou 2 e não perdeu nenhum.
- Custo menor: 1 chamada, 7,3 s e 1.964 tokens por pergunta.

Onde ainda erra

- Escolha da operação no Planner (24 perguntas), como no E2.
- Histórico e leitura do relatório (26).
- Deslizes de formato que o Executor do E2 perdoava (11).

O que ajustar

- Rodar o modo REUSE_PLANS_FROM_CSV para isolar o efeito da calculadora.
- Inverter a prioridade de nomes (o passo vence) ou rejeitar colisões.
- Mesmo ajuste de operação sugerido no E2 ("change" → sub).